

Exploratory Data Analysis

Zuil Pirola

Data Wrangling para EDA


Ir além do “como fazer”

Focar em:

- decisões
- impacto analítico
- erros comuns

Pensar como um data scientist

A realidade




What's the least enjoyable part of data science?

- Building training sets: 10%
- Cleaning and organizing data: 57%
- Collecting data sets: 21%
- Mining data for patterns: 3%
- Refining algorithms: 4%
- Other: 5%

<https://www.forbes.com/sites/gilpress/2016/03/23/data-preparation-most-time-consuming-least-enjoyable-data-science-task-survey-says/>

A realidade



<https://medium.com/@vanshikagoel/data-science-life-cycle-in-5-steps-3fe720b2a2fe>

Data Wrangling

Qual foi o dataset mais problemático que vocês já trabalharam?

Missing Data

Pode conter informação

Pode introduzir viés

- MCAR → aleatório
- MAR → depende de outras variáveis
- MNAR → depende do próprio valor

Missing Data

MCAR (Missing Completely At Random)

- Dados ausentes completamente ao acaso
 - Não depende de nenhuma variável
- Ex: falha aleatória no sensor

MAR (Missing At Random)

- Depende de outras variáveis observadas
- Ex: renda ausente mais comum em pessoas jovens

Missing Data

MNAR (Missing Not At Random)

- Depende do próprio valor que está faltando
Ex: pessoas com alta renda não reportam renda

Missing Estruturado

- Ausência faz parte do fenômeno
Ex: “número de filhos” = NA para pessoas sem filhos


Estratégias

- Remover(Drop)
- Preencher (mean, median, mode)
- Forward/backward fill - series temporais X ordenados
- Manter como categoria - Criar uma feature para separar os missings

Trade-offs

- Média distorce distribuição
- Remover reduz dados
- Preencher pode criar padrões falsos

O que é um outlier?



O que é um outlier?

- Valor extremo
- Mas nem sempre erro - comportamento raro
- IQR
- Remover?

Pode ser:

- erro de medição
- comportamento raro
- evento importante

O outlier pode ser o mais importante

Transformar dados

As vezes os dados não estão em formato como queremos e portanto:

- `replace()` - Ex: trocar "M" → "Male"
- `map()` - {"PT": "Portugal", "ES": "Spain"}
- `apply()` - Aplicar funções
- vectorized ops - `df["age"] * 2`

Transformar dados

As vezes os dados não estão em formato como queremos e portanto:

- `replace()` - Ex: trocar "M" → "Male"
- `map()` - {"PT": "Portugal", "ES": "Spain"}
- `apply()` - Aplicar funções
- vectorized ops - `df["age"] * 2`

Transformar dados

Binning

- Útil para:
 - interpretação
 - modelos simples

Mas cuidado:

- perde informação
- cria cortes arbitrários

Sobre manipular Strings

- “Lisboa”, “lisbon”, “LISBOA”
- espaços extras
- erros de digitação
- encontrar padrões (“,” ou “|”)
- limpar texto (Cala-te..... Sério)

Grande parte do trabalho real é limpar texto

Merge e Join

Dados vêm de múltiplas fontes

Para join:

- Inner - Interseção
- Left/Right - Mantem os dados de uma das fontes e add a outra (poe NaN)
- Outer - União

O tipo de join define quais dados “sobrevivem” na análise

Reshaping

wide → colunas (Cada variável está em **colunas diferentes**)

long → linhas (Variáveis são organizadas em **linhas**)

id	sale_2023	sale_2024
1	1000	2100
id	year	sale
1	2023	1000
2	2024	2100

Pipeline

1. Understand
2. Clean
3. Transform
4. Integrate
5. Validate

Importante:

etapas claras
reproduzível
documentado

“Entenda os dados, limpe-os, transforme-os, integre fontes e valide antes de analisar.”

Obrigado!