

Exploratory Data Analysis

Zuil Pirola

Agregação e Operações em Grupo

Objetivo:

- Entender como resumir dados
 - Identificar padrões por grupos
- Preparar dados para análise e modelagem

dados brutos raramente são interpretáveis diretamente

GroupBy = dividir dados em grupos

Exemplo:

Dados de vendas → agrupar por cidade

Resultado:

- Média por cidade
- Total por cidade
- Contagem por cidade

Split → Apply → Combine

GroupBy = dividir dados em grupos




Figure 10-1. Illustration of a group aggregation

GroupBy = dividir dados em grupos

Qual a diferença entre agrupar por cidade vs por produto?
Podemos agrupar por mais de uma coluna?

Split-Apply-Combine

Split:

Dividir dados em grupos

Apply:

Aplicar função em cada grupo

Combine:

Juntar resultados

Exemplo:

Vendas → Agrupar por loja → Média → Resultado final

Exemplo Prático

Esse é o modelo mental MAIS importante em EDA.

Dataset:

Loja | Produto | Vendas

A | X | 100

A | Y | 200

B | X | 150

Agrupar por Loja:

Loja | Média de Vendas

A | 150

B | 150

Agregações Comuns

Funções mais usadas:

- `mean()` → média
- `sum()` → soma
- `count()` → contagem
- `std()` → desvio padrão
- `min()` / `max()`

Podemos aplicar várias ao mesmo tempo

Transformação vs Agregação

Agregação:

Reduz número de linhas

Transformação:

Mantém número de linhas

Exemplo:

Normalizar vendas dentro de cada grupo

Transformação vs Agregação

	departamento	funcionario	salario
0	Vendas	Ana	3000
1	Vendas	Bruno	3500
2	Vendas	Carlos	4000
3	TI	Diana	5000
4	TI	Eduardo	5500
5	RH	Fernanda	2800
6	RH	Gabriel	3200

agg()

	media_salario
departamento	
RH	3000.0
TI	5250.0
Vendas	3500.0

transform

	departamento	funcionario	salario	media_departamento
0	Vendas	Ana	3000	3500.0
1	Vendas	Bruno	3500	3500.0
2	Vendas	Carlos	4000	3500.0
3	TI	Diana	5000	5250.0
4	TI	Eduardo	5500	5250.0
5	RH	Fernanda	2800	3000.0
6	RH	Gabriel	3200	3000.0

Agrupamento Avançado

Podemos agrupar por:

- Colunas
- Funções
- Índices

Exemplo:

Agrupar por ano (extraído da data)

Missing Values por Grupo

Analisar dados faltantes por grupo

Exemplo:

- % de valores faltantes por região

Importante para:

- qualidade dos dados
viés na análise

Missing não é aleatório muitas vezes.

Pivot Tables

Pivot Table = reorganização dos dados

Estrutura:

- Linhas
- Colunas
- Valores

Exemplo:

Vendas por Produto (colunas) e Região (linhas)

Pivot Tables

	cidade	produto	vendas	quantidade
0	Lisboa	Notebook	1200	3
1	Lisboa	Mouse	150	10
2	Lisboa	Notebook	1300	2
3	Porto	Notebook	1000	2
4	Porto	Mouse	200	12
5	Porto	Mouse	180	9



```
pivot = pd.pivot_table(  
    df,  
    values="vendas",  
    index="cidade",  
    columns="produto",  
    aggfunc="sum"  
)  
print(pivot)
```



produto	Mouse	Notebook
cidade		
Lisboa	150	2500
Porto	380	1000

Muito usado em BI

Crosstab

Crosstab = tabela de frequência

Exemplo:


Sexo vs Compra

Resultado:

Contagem de ocorrências

Crosstab

	genero	produto
0	F	Notebook
1	M	Mouse
2	F	Mouse
3	F	Notebook
4	M	Teclado
5	M	Notebook
6	F	Teclado
7	M	Mouse
8	F	Notebook
💡	M	Mouse



produto	Mouse	Notebook	Teclado
genero			
F	1	3	1
M	3	1	1

Muito usado para:
variáveis categóricas
análise de associação

Conclusão Geral

EDA + Tempo:

- Entender padrões
- Identificar tendências
- Preparar para modelos

Ferramentas essenciais:

GroupBy + Resampling + Rolling

Testando conhecimento

Dataset:

Cidade | Produto | Vendas

SP | A | 100

SP | B | 200

RJ | A | 150

RJ | B | 250

Pergunta:

Qual ferramenta você usaria para calcular a média de vendas por cidade?

Testando conhecimento

Dataset:

Cidade | Produto | Vendas

SP | A | 100

SP | B | 200

RJ | A | 150

RJ | B | 250

GroupBy

Pergunta:

Qual ferramenta você usaria para calcular a média de vendas por cidade?

Testando conhecimento

Loja | Vendas

A | 100

A | 200

A | 300

B | 150

B | 250

Pergunta:

Como obter, por loja:

- média de vendas
- total vendido
- número de vendas?

Testando conhecimento

Loja | Vendas

A | 100

A | 200

A | 300

B | 150

B | 250

GroupBy

Pergunta:

Como obter, por loja:

- média de vendas
- total vendido
- número de vendas?

Testando conhecimento

Dataset:

Região | Produto | Vendas

Sul | A | 100

Sul | B | 200

Norte | A | 150

Norte | B | 300

Pergunta:

Como criar uma tabela onde:

- Linhas = Região
- Colunas = Produto
- Valores = Soma de vendas?

Testando conhecimento

Dataset:

Região | Produto | Vendas

Sul | A | 100

Sul | B | 200

Norte | A | 150

Norte | B | 300

Pivot table

Pergunta:

Como criar uma tabela onde:

- Linhas = Região
- Colunas = Produto
- Valores = Soma de vendas?

Testando conhecimento

Sexo | Comprou

M | Sim

F | Não

M | Sim

F | Sim

F | Não

Pergunta:

Como analisar a frequência de compras
por sexo?

Testando conhecimento

Sexo | Comprou

M | Sim

F | Não

M | Sim

F | Sim

F | Não

Crosstab

Pergunta:

Como analisar a frequência de compras
por sexo?

Obrigado!