

Exploratory Data Analysis

Zuil Pirola

Dados Temporais em Análise Exploratória de Dados

Como o tempo muda a forma de analisar dados?

"O objetivo não é prever o futuro, mas aprender a compreender comportamento temporal."

Porque estudar dados temporais?

Exemplos:

- E-commerce
- Sensores IoT
- Meteorologia
- Mobilidade urbana
- Bolsa de valores
- Redes sociais

O que todos possuem em comum? TEMPO!

Dados tradicionais vs dados temporais

idade	Salário		Data	Vendas
25	1200		Jan	100
40	2500		Fev	120

Em dados temporais a ordem importa.

O que muda quando existe tempo?

Valor + Tempo = Contexto

- Cresceu?
- Caiu?
- Existe padrão?
- Existe repetição?

Evolução e comportamento.


Objetivos da EDA temporal

Queremos encontrar:

- Tendências (ao longo do tempo cresce, diminui?)
- Sazonalidade (padrões que se repetem com o tempo)
- Anomalias (desvio do comportamento esperado)
- Dados ausentes (falta um mês ou 13 dias de dados)

O que é Timestamp?

Representa (de maneira estruturada) um instante específico no tempo



Granularidade temporal

- Ano
- Mês
- Dia
- Hora
- Minuto
- Segundo

Toda aplicação precisa da mesma precisão?

Anatomia de um Timestamp

2025-05-20 14:35:22


- Ano
- Mês
- Dia
- Hora
- Minuto
- Segundo

Por que dessa ordem?

Mais de uma variável dentro da mesma.

Escalas temporais

"Maior detalhe produz mais informação mas também mais complexidade."



Formatos diferentes de data

15/04/2025

2025-04-15

Apr 15 2025

04-15-2025

Qual mais usado? Como eles vem?

Ambiguidade temporal

03/04/2025

Março 4 ou Abril 3? MM/DD/AAAA ou DD/MM/AAAA?

Ambiguidade temporal

Texto não é Timestamp

Antes:

Object (string)

Depois:

Datetime

Muito comum o trabalho de conversão

Porque converter corretamente?

Identificar o padrão: DD/MM/AAAA

Pipeline de exemplo:

- Extrair Dia
- Extrair Mes
- Extrair Ano
- Agrupar

Pré requisito para EDA temporal.

O tempo esconde informação

2025-05-20 19:45

Podemos obter:

- Ano
- Hora
- Dia
- Semana <—
- Mês

Múltiplas variáveis!

Hora do dia importa?

Delivery:

12h → pico almoço

20h → pico jantar

Fenómenos reais podem mudar dependendo da hora ou com o tempo.


Dia da semana importa?

Segunda	10
Terça	20
Quarta	24
Quinta	50
Sexta	300
Sabado	372
Domingo	50

Venda de bebida em uma tasca qualquer da cidade.

Mês do ano importa?

Índice de Faturamento Online - Brasil



<https://blog.ideiamais.com.br/crescimento-vendas-no-e-commerce-2021-4841/>


Eventos especiais

- Natal
- Black Friday
- Feriados
- Covid****

Discussão guiada

Investimento em infraestruturas de transportes caiu abruptamente a partir de 2010

Valores em milhões de euros



Fonte: Gabinete de Estratégia e Estudos do Ministério da Economia

Nota: Os dados relativos às estradas incluem a rede nacional e as autoestradas. Exclui estradas municipais.

<https://eco.sapo.pt/2024/02/28/partidos-concordam-com-nova-vaga-de-investimento-em-infraestruturas-mas-ha-diferencas/>

O que é índice temporal?

O índice temporal é quando a variável de tempo deixa de ser apenas uma coluna comum e passa a organizar toda a estrutura dos dados. Isso permite realizar operações temporais de forma eficiente, como filtragem por datas, agrupamentos por período, deslocamentos temporais (shift), janelas móveis (rolling) e reamostragem (resampling).

O que é índice temporal?

Exemplo:

- Selecionar apenas dados de janeiro de 2025
- Calcular média móvel dos últimos 7 dias
- Comparar vendas do dia atual com o dia anterior usando `shift()`
- Agregar dados diários em valores mensais usando `resample()`

Porque ordenar importa?

Data	Vendas
2025-01-01	100
2025-01-02	120
2025-01-03	130
2025-01-04	150
2025-01-05	170

Data	Vendas
2025-01-03	130
2025-01-01	100
2025-01-05	170
2025-01-02	120
2025-01-04	150

O mesmo dado pode contar histórias diferentes dependendo da organização.

Porque ordenar importa?

Hora	Temp
8h	20
9h	21
10h	22
10h	24
11h	25

Duplicados podem indicar erro ou comportamento legítimo.

Dados ausentes

Hora	Vendas
1 Jan	20
2 Jan	21
4 Jan	22
5 Jan	24
10 Jan	25

Missing? Não vendeu? Lacunas temporais são comuns.

Horário vs Diário

Dados horários (maior granularidade)	
Hora	Temperatura
08h	21°
09h	22°
10h	24°
11h	23°
12h	25°
↓	
Dados diários (agregados)	
Dia	Temperatura Média
Segunda	23°

Diário vs Mensal

Dados diários	
Dia	Vendas
01	100
02	120
03	90
04	110
↓	
Dados mensais (agregados)	
Mês	Média
Janeiro	105

Agregar reduz detalhe mas simplifica. Quando fazer?

Múltiplas agregações

Horário (alta granularidade)	
Hora	Temperatura
08h	20°
09h	22°
10h	25°
11h	24°
12h	23°
↓	
Diário (agregação intermédia)	
Dia	Temperatura Média
Segunda	22°
Terça	24°
Quarta	23°
↓	
Mensal (visão agregada)	
Mês	Temperatura Média
Janeiro	23°

Date Ranges

Maneira de criar sequencia de dados em sequencia. (Excel faz isso)

Ajudam na organização temporal.

Shift (Deslocamento Temporal)

Série original

Mês	Vendas
Jan	100
Fev	120
Mar	130

↓

Aplicando `shift(1)`

Mês	Vendas	Mês Anterior
Jan	100	—
Fev	120	100
Mar	130	120

Shift(1)

Shift(12)

Comparar períodos:

- valor do período anterior (*lag*);
- crescimento entre períodos;
- comparação temporal;

Deslocamento Temporal

Lag traz passado para contexto atual.

Jan → 100

Fev → 120

Crescimento:
120-100


Dia	Preço	Lag(1)	Lead(1)
Seg	100	—	103
Ter	103	100	101
Qua	101	103	—

Resampling


Dados horários	
Hora	Vendas
08h	10
09h	15
10h	20
11h	25
↓	
Resampling diário (D)	
Dia	Soma Vendas
01-Jan	70

Pandas faz isso para nós!


Tendencia



Tendencia




Sazonalidade



<https://filipezabala.com/ea/tratamento.html>

Outliers




http://www.sbai2013.ufc.br/pdfs/8721_sem_copyright.pdf

Leitura integrada

O que é:

- Tendência? (Gráfico de linha temporal e média móvel)
- Sazonalidade? (Boxplot do período e grafico temporal)
- Anomalias? (Boxplot do período)
- Dados ausentes? (Analise da linha temporal)

Resumo



Obrigado!